IA · REGRESSÃO LINEAR

GasolinIA

Previsão de Consumo de Combustível com Aprendizado de Máquina

Kauan Magri · Luiz Felipe
Raciocínio Matemático para Computação | 2026

Prof. Eduardo Z. Sartoretto · Engenharia de Software

01 Contextualização do Problema

O Problema

Prever o consumo de combustível de um veículo com base nas suas características técnicas, sem precisar testá-lo na prática.

O que o Modelo Prevê

O consumo médio em km/L de um carro que ele nunca viu antes, com base nas 5 características técnicas do veículo.

Economia

Ajuda motoristas a escolher carros mais eficientes

Sustentabilidade

Menor consumo = menos emissões de CO_2

Automação

IA substitui testes físicos custosos

02 Dados Utilizados — Features

Cilindrada (L)

Tamanho do motor em litros

ex: 1.0, 1.6, 2.0

Aceleração (s)

Tempo de 0 a 100 km/h

ex: 3.9 a 15.0 s

Peso (kg)

Massa total do veículo

ex: 870 a 2200 kg

Ano do Modelo

Ano de fabricação do veículo

ex: 2010 a 2023

Potência (cv)

Força do motor em cavalos-vapor

ex: 65 a 510 cv

Saída Esperada (y)

Consumo médio em km/L por veículo

Matriz: 15 × 5 ✅ (mínimo exigido: 10×5)

03 Representação Matemática

Matriz X (15 linhas × 5 colunas)

A matriz X do dataset tem **15 linhas × 5 colunas:**

Carro	Cilindrada (L)	Peso (kg)	Potência (cv)	Aceleração (s)	Ano
Fiat Uno	1.0	870	65	15.0	2010
VW Gol	1.0	940	75	14.0	2012
Fiat Mobi	1.0	865	75	13.5	2020
HB20	1.0	975	80	13.0	2019
Onix	1.0	1020	82	12.5	2021
Fiat Strada	1.3	1200	109	11.0	2022
VW Polo	1.6	1150	120	11.5	2018
Jeep Renegade	1.8	1440	139	9.5	2021
Honda Civic	2.0	1345	154	8.5	2022
Toyota Corolla	2.0	1380	177	8.0	2023
VW Jetta	2.0	1260	132	9.2	2020
Toyota SW4	2.8	2120	177	11.0	2020
BMW M3	3.0	1730	510	3.9	2023
Ford F-150	5.0	2200	400	6.5	2022
VW Up	1.3	1100	95	12.0	2021

Vetor y (consumo real em km/L)

E o vetor **y** (o que o modelo tenta prever):

Carro	Consumo (km/L)
Fiat Uno	14.2
VW Gol	13.5
Fiat Mobi	14.8
HB20	13.0
Onix	12.8
Fiat Strada	11.5
VW Polo	11.8
Jeep Renegade	9.5
Honda Civic	10.5
Toyota Corolla	10.0
VW Jetta	11.2
Toyota SW4	7.2
BMW M3	6.2
Ford F-150	5.8
VW Up	12.5

Cada linha de X representa um carro; o valor correspondente em y é o consumo real que o modelo aprende a reproduzir.

04 Modelo Supervisionado

Tipo de Problema

Regressão — a saída é um valor numérico contínuo (km/L), não uma categoria discreta.

Modelo Utilizado

Regressão Linear Múltipla — LinearRegression do scikit-learn (Python).

Como Ocorre o Treinamento

1 — Entrada
Matriz X (15×5 features)

→

2 — Treino
70% dos dados (10 carros)

→

3 — OLS
Minimiza soma dos erros²

→

4 — Coef. β
Pesos de cada feature

→

5 — Previsão
$\hat{y} = \beta_0 + \beta_1 x_1 + \ldots + \beta_5 x_5$

Split: 70% treino (10 carros) · 30% teste (5 carros) · random_state=42

05 Explicação Teórica do Modelo

$$\hat{y} = \beta_0 + \beta_1 \cdot \text{Cilindrada} + \beta_2 \cdot \text{Peso} + \beta_3 \cdot \text{Potência} + \beta_4 \cdot \text{Aceleração} + \beta_5 \cdot \text{Ano}$$

Objetivo

Encontrar uma função linear que relacione as features de entrada com o consumo de saída (km/L).

Funcionamento

Calcula os coeficientes β via Mínimos Quadrados Ordinários (OLS), minimizando a soma dos erros ao quadrado.

Aplicações

Preço de imóveis, previsão de salário, estimativa de temperatura, previsão de notas acadêmicas.

I/O do Modelo

Entrada: 5 características técnicas do carro. Saída: consumo estimado em km/L (valor contínuo).

Coeficientes aprendidos (β): Cilindrada 1.534 · Aceleração 0.196 · Ano 0.067 · Potência −0.004 · Peso −0.009

06 Implementação em Python

```
# Organização dos dados

dados = {
  'Cilindrada_L': [1.0, 1.3, 1.6, ...]
  'Consumo_kmL':  [14.2, 11.5, ...]
}

# Treino e teste
X_treino, X_teste, y_treino, y_teste =
  train_test_split(X, y,
    test_size=0.3, random_state=42)

# Treinamento do modelo
modelo = LinearRegression()
modelo.fit(X_treino, y_treino)
```

```
# Realização de previsão

entrada = np.array([[
  cilindrada, peso,
  potencia, acel, ano
]])
consumo = modelo.predict(
  entrada)[0]
```

🛠 Stack Tecnológico

- Python 3
- scikit-learn
- NumPy / Pandas
- Flask (web UI)
- Chart.js

07 Resultados

0.994

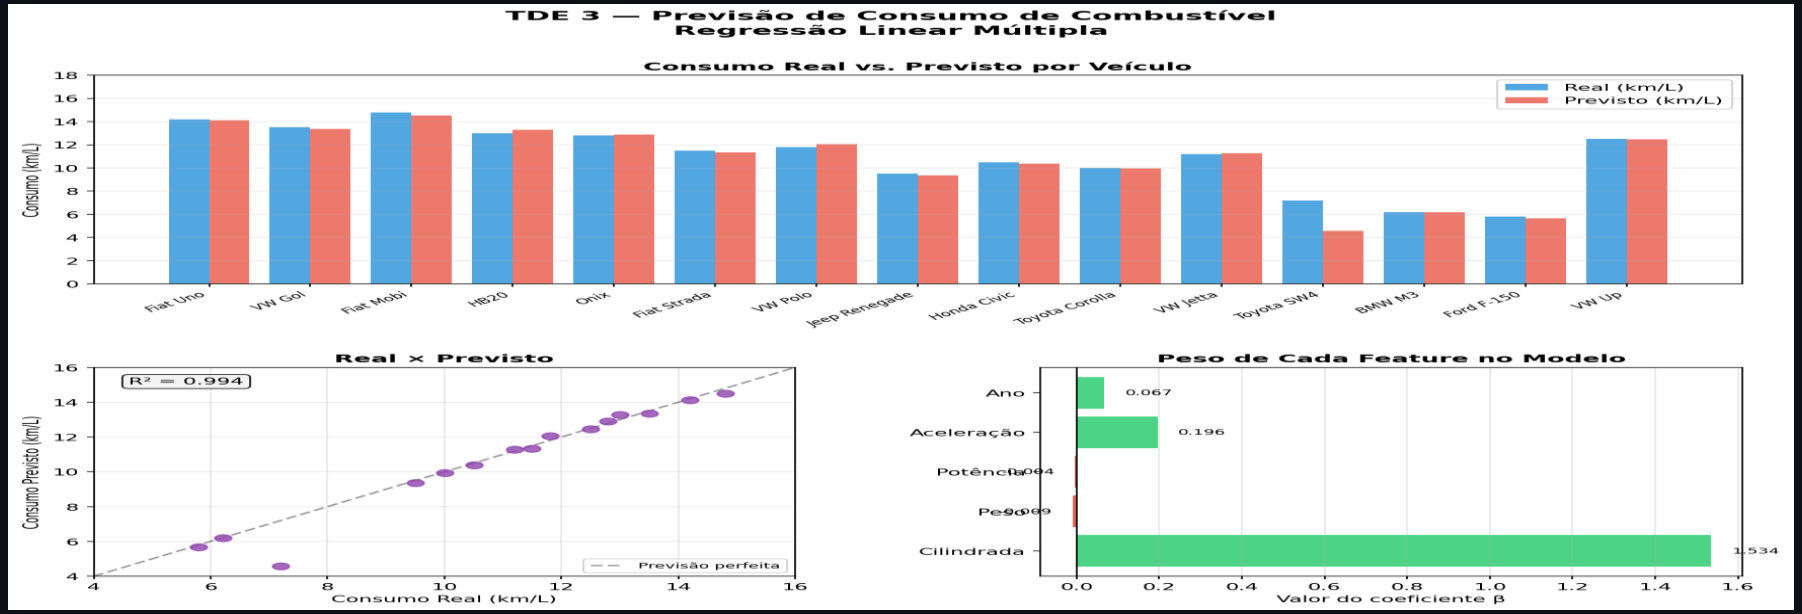
R^2 no treino

0.69

RMSE km/L no teste

15

Carros na base de dados



08 Limitações do Modelo

Dataset Pequeno

Apenas 15 veículos foram usados no treinamento. Bases maiores (centenas de carros) produziriam métricas mais confiáveis e generalizáveis.

Linearidade

A Regressão Linear assume relação linear entre features e consumo. Fenômenos não-lineares (ex: turbo, hibridização) podem não ser capturados corretamente.

Overfitting no Treino

$R^2 = 0.994$ no treino vs RMSE ≈ 0.69 km/L no teste indica que o modelo pode ter se ajustado demais aos poucos dados de treinamento.

Features Ausentes

Variáveis relevantes como tipo de câmbio (manual/automático), tração, aerodinâmica e tipo de combustível não foram incluídas no modelo.

Veículos Elétricos / Híbridos

O modelo foi treinado apenas com carros a combustão. Não é aplicável a EVs ou híbridos plug-in, cujo consumo segue lógica distinta.

Condições de Uso

O consumo real varia com estilo de condução, tráfego, temperatura e altitude. O modelo prevê apenas a média técnica do fabricante.

GasolinIA

Regressão Linear Múltipla aplicada com sucesso à previsão de consumo de combustível.

R^2 0.994	15 carros	5 features	Flask + AI
Precisão no treino	Base de dados	Variáveis utilizadas	App web interativa

Kauan Magri · Luiz Felipe

Raciocínio Matemático para Computação | Prof. Eduardo Z. Sartoretto | 23/06/2026

Obrigado!