TDE 3 — Raciocinio Matematico para Computacao

GasolinIA

Previsao de Consumo de Combustivel com Regressao Linear Multipla

Engenharia de Software · Prof. Eduardo Z. Sartoretto · 2026
Kauan Magri · Luiz Felipe

1. Contextualizacao do Problema

O GasolinIA e um projeto de aprendizado de maquina supervisionado que tem como objetivo prever o consumo de combustivel de veiculos automotores, medido em quilometros por litro (km/L), com base em caracteristicas tecnicas do veiculo. O problema e relevante tanto do ponto de vista economico — ajudando consumidores a estimar gastos com combustivel — quanto ambiental, uma vez que veiculos menos eficientes emitem mais CO_2.

O modelo recebe como entrada cinco caracteristicas do veiculo e retorna uma estimativa numerica do consumo. Trata-se, portanto, de um problema de **regressao supervisionada**, pois a variavel de saida e continua e os dados de treinamento possuem rotulos conhecidos.

2. Dados Utilizados

A base de dados foi construida com 15 veiculos reais do mercado brasileiro, abrangendo desde carros populares (Fiat Uno, Onix) ate SUVs e veiculos de alta performance (BMW M3, Ford F-150). A matriz de features X possui dimensao **15 x 5**, atendendo ao requisito minimo de 10 x 5 exigido pelo trabalho.

Descricao das features (colunas de X):

Feature	Tipo	Descricao
Cilindrada (L)	Numerica	Tamanho do motor em litros
Peso (kg)	Numerica	Massa total do veiculo em quilogramas
Potencia (cv)	Numerica	Forca do motor em cavalos-vapor
Aceleracao (s)	Numerica	Tempo de 0 a 100 km/h em segundos
Ano do modelo	Numerica	Ano de fabricacao do veiculo

Variavel alvo (vetor y):

O vetor y contem o consumo medio em km/L de cada veiculo. E o valor que o modelo aprende a prever a partir das features acima.

3. Representacao Matematica

A matriz de entrada X e o vetor de saida y sao representados conforme abaixo. Cada linha de X corresponde a um veiculo; cada coluna, a uma feature.

Matriz X (15 x 5) com vetor y:

Carro	Cilind. (L)	Peso (kg)	Potenc. (cv)	Acel. (s)	Ano	y (km/L)
Fiat Uno	1.0	870	65	15.0	2010	**14.2**
VW Gol	1.0	940	75	14.0	2012	**13.5**
Fiat Mobi	1.0	865	75	13.5	2020	**14.8**
HB20	1.0	975	80	13.0	2019	**13.0**
Onix	1.0	1020	82	12.5	2021	**12.8**
Fiat Strada	1.3	1200	109	11.0	2022	**11.5**
VW Polo	1.6	1150	120	11.5	2018	**11.8**
Jeep Renegade	1.8	1440	139	9.5	2021	**9.5**
Honda Civic	2.0	1345	154	8.5	2022	**10.5**
Toyota Corolla	2.0	1380	177	8.0	2023	**10.0**
VW Jetta	2.0	1260	132	9.2	2020	**11.2**
Toyota SW4	2.8	2120	177	11.0	2020	**7.2**
BMW M3	3.0	1730	510	3.9	2023	**6.2**
Ford F-150	5.0	2200	400	6.5	2022	**5.8**
VW Up	1.3	1100	95	12.0	2021	**12.5**

4. Modelo Supervisionado

O problema e classificado como **regressao**, pois a variavel de saida (consumo em km/L) e um valor numerico continuo — e nao uma categoria ou classe discreta.

O modelo utilizado e a **Regressao Linear Multipla**, implementada com a biblioteca scikit-learn (Python). O treinamento ocorre em tres etapas:

	Separacao dos dados	70% dos dados sao usados para treino; 30% para teste.
2	**Ajuste dos coeficientes**	O algoritmo calcula os pesos B pelo metodo dos Minimos Quadrados Ordinarios (OLS), minimiz
	Avaliacao do modelo	O modelo e avaliado com R2 e RMSE no conjunto de teste para medir a qualidade das previsoe

5. Explicacao Teorica do Modelo

Objetivo: encontrar uma funcao linear que relacione multiplas variaveis de entrada (features) com uma variavel de saida continua (consumo).

Funcionamento basico: o modelo aprende uma equacao da forma:

```
y_pred = B0 + B1*x1 + B2*x2 + B3*x3 + B4*x4 + B5*x5
```

Onde cada Bi e um coeficiente (peso) aprendido durante o treinamento, e cada xi representa uma feature do veiculo. Os coeficientes aprendidos pelo modelo foram:

Coeficiente	Feature	Valor aprendido
B0	Intercepto	-116.9436
B1	Cilindrada (L)	+1.5336
B2	Peso (kg)	-0.0094
B3	Potencia (cv)	-0.0035
B4	Aceleracao (s)	+0.1957
B5	Ano	+0.0672

Interpretacao: o coeficiente negativo do peso indica que veiculos mais pesados tendem a consumir mais (menor km/L). O coeficiente positivo da aceleracao indica que carros que demoram mais para acelerar (geralmente motores menores) tendem a ser mais economicos. O ano positivo mostra que veiculos mais novos sao, em media, mais eficientes.

6. Resultados e Metricas

Metrica	Valor	Interpretacao
R2 (treino)	0.9944	O modelo explica 99.4% da variancia dos dados de treino
R2 (teste)	0.8462	84.6% da variancia explicada nos dados nao vistos
RMSE	1.18 km/L	Erro medio de apenas 1.18 km/L nas previsoes de teste

Exemplos de previsoes do modelo:

Carro	Real (km/L)	Previsto (km/L)	Erro
Fiat Uno	14.2	14.1	-0.1
Onix	12.8	12.9	+0.1
Honda Civic	10.5	10.4	-0.1
Toyota SW4	7.2	4.6	-2.6
BMW M3	6.2	6.2	0.0
Ford F-150	5.8	5.7	-0.1

7. Limitacoes do Modelo

Apesar dos bons resultados, o modelo apresenta algumas limitacoes importantes:

• **Base pequena:** Com apenas 15 amostras, o modelo pode nao generalizar bem para veiculos muito diferentes dos presentes no dataset. Em producao, bases com milhares de registros

seriam ideais.

• **Linearidade:** A regressao linear assume que a relacao entre as features e o consumo e linear, o que pode nao ser verdade em todos os casos.

• **Features ausentes:** Fatores como tipo de combustivel (alcool vs gasolina), tracao (4x4 ou nao), tipo de transmissao e condicoes de uso nao foram considerados.

• **SW4 com erro maior:** O Toyota SW4 apresentou erro de -2.6 km/L, possivelmente por ser um outlier na base (veiculo muito pesado com motor relativamente economico para seu porte).